

Generación de Señales ECG Sintéticas Condicionadas mediante TCN-cVAE para Aumentación de Datos en Clasificación de Arritmias

[Marx Ríos], [Nestor Allende], [Renzo Luna]

[UPCH / Ingeniería Biomédica][Lima, Peru]

Abstract

El diagnóstico de arritmias cardíacas a partir de señales de electrocardiograma (ECG) representa un desafío clínico relevante. Los modelos de aprendizaje profundo para su clasificación automática se ven frecuentemente limitados por la escasez de datos etiquetados y el severo desbalance de clases en los conjuntos disponibles. En este trabajo se propone un generador de señales ECG sintéticas basado en una red neuronal convolucional temporal con variational autoencoder condicional (TCN-cVAE), entrenado sobre el conjunto PhysioNet ECG-Arrhythmia de 12 derivaciones a 500 Hz. El modelo aprende representaciones latentes específicas por clase clínica SNOMED-CT y sintetiza latidos de 650 ms (325 muestras) con morfología preservada. La utilidad clínica de las señales sintéticas se evalúa mediante un paradigma Train-on-Synthetic-Test-on-Real (TSTR) con un clasificador TCN independiente evaluado en tres modos: solo datos reales (modo A), solo sintéticos (modo B) y datos aumentados real+sintético (modo C). Los resultados muestran que el modo C alcanza un recall macro de 55.65%, superando al modo A (40.64%) y al modo B (47.83%), evidenciando que la aumentación con datos sintéticos mejora la sensibilidad sobre clases minoritarias. Se presentan además métricas de fidelidad distribucional (MMD², SWD, distancia de Fréchet latente) y evaluación morfológica clínica (intervalos PR, QRS, QT y detección del pico R).

Index Terms — ECG sintético, TCN-cVAE, arritmia, aumentación de datos, TSTR, PhysioNet, aprendizaje profundo.

I. INTRODUCCIÓN

El electrocardiograma (ECG) es la herramienta diagnóstica estándar para la detección de arritmias cardíacas. Sin embargo, la interpretación manual es costosa y susceptible a variabilidad inter-observador. Los modelos de clasificación automática basados en aprendizaje profundo han mostrado resultados prometedores [1], pero su rendimiento depende críticamente de la disponibilidad de grandes volúmenes de datos anotados por expertos, los cuales son escasos y presentan desbalances severos entre clases.

Una alternativa para mitigar esta limitación es la generación de datos sintéticos mediante modelos generativos profundos. Las redes generativas adversariales (GAN) y los autoencoders variacionales (VAE) han sido explorados para síntesis de señales biomédicas [2, 3]. No obstante, las GAN presentan inestabilidad durante el entrenamiento y propensión al colapso de modo, mientras que los VAE convencionales presentan limitaciones en la fidelidad de las señales generadas.

En este trabajo proponemos una arquitectura TCN-cVAE que combina redes neuronales convolucionales temporales (TCN) con un VAE condicional (cVAE), aprovechando el campo receptivo amplio de las TCN (>325 muestras con dilataciones [1,2,4,8,16,32]) y la capacidad del cVAE de controlar la clase clínica de la señal generada mediante un vector de condicionamiento SNOMED-CT. La evaluación sigue el paradigma TSTR [4] para cuantificar la utilidad downstream de los datos sintéticos.

II. METODOLOGÍA

A. Dataset

Se empleó el conjunto PhysioNet ECG-Arrhythmia (versión 1.0.0) [5], compuesto por registros de ECG de 12 derivaciones a 500 Hz, etiquetados con códigos SNOMED-CT. Cada registro fue preprocesado mediante filtro paso-alto (0.5 Hz) y paso-bajo (40 Hz). Los latidos individuales se extrajeron centrados en el pico R (Pan-Tompkins) con ventana de 650 ms (125 muestras antes, 200 después del pico R), para un total de 325 muestras por latido. El conjunto resultante fue dividido en tres grupos: 60% para entrenamiento del generador (GEN_SPLIT), 20% como pool de datos reales del clasificador (CLF_REAL) y 20% como conjunto held-out de evaluación (CLF_HELD), nunca visto durante el entrenamiento.

B. Arquitectura TCN-cVAE

El modelo propuesto consta de un encoder y un decoder, ambos basados en una pila de bloques residuales TCN con dilataciones (1, 2, 4, 8, 16, 32), proporcionando un campo receptivo total de 505 muestras, suficiente para capturar el latido completo de 325 muestras. Cada bloque TCN emplea WeightNorm [6] en lugar de BatchNorm, respetando la causalidad estadística requerida en redes temporales.

El encoder proyecta la señal de entrada $x \in \mathbb{R}^{325}$ junto con el vector de condicionamiento one-hot $c \in \{0,1\}^C$ al espacio latente gaussiano $q(z|x,c) = N(\mu, \sigma^2 I)$, con $z \in \mathbb{R}^{32}$. El decoder reconstruye la señal a partir de $p(x|z,c)$. La función de pérdida combina MSE de reconstrucción y divergencia KL con $\beta=0.035$, con un annealing lineal durante 30 épocas warmup y un máximo de 140 épocas.

Durante el entrenamiento se consideraron únicamente seis categorías diagnósticas. Para ello, se seleccionaron las cinco clases con mayor número de registros dentro de la base de datos y se definió una sexta categoría, denominada *Others*, en la que se agruparon las dieciocho clases restantes debido a su baja representatividad individual, dado que cada una de ellas aportaba menos del 2 % de las muestras totales del conjunto de datos.

Esta reducción del número de categorías respondió a criterios tanto metodológicos como computacionales. Desde el punto de vista metodológico, permitió atenuar el elevado desbalance entre clases y evitar que categorías con una cantidad limitada de muestras afectaran el aprendizaje de representaciones latentes robustas y estadísticamente significativas. Desde la perspectiva computacional, la utilización de un conjunto de clases más acotado y de un volumen reducido de datos contribuyó a disminuir el tiempo de entrenamiento y los requerimientos de memoria RAM, posibilitando una implementación más eficiente del modelo sin comprometer la representatividad de las arritmias de mayor relevancia dentro del conjunto de datos.

C. Clasificador TCN y Paradigma TSTR

Para evaluar la utilidad downstream de los datos sintéticos se entrenó un clasificador TCN independiente (TCNClassifier), con 128 canales, mismas dilataciones que el generador, y un bloque de atención temporal. La función de pérdida empleada fue Focal Loss ($\gamma=2$) para mitigar el desbalance de clases. El clasificador se evaluó en cuatro modos sobre el conjunto CLF_HELD:

Modo A (REAL $\rightarrow$ test REAL): el clasificador fue entrenado exclusivamente con datos reales y evaluado sobre el conjunto held-out real, constituyendo el escenario de referencia o baseline.

Modo B (SINT $\rightarrow$ test REAL): el clasificador fue entrenado únicamente con señales sintéticas generadas por el TCN-cVAE y posteriormente evaluado sobre datos reales no vistos, siguiendo el paradigma Train on Synthetic, Test on Real (TSTR). Este escenario permite determinar en qué medida las señales sintéticas contienen información suficiente para aprender patrones discriminativos transferibles a los registros reales.

Modo C (REAL + SINT $\rightarrow$ test REAL): el clasificador fue entrenado utilizando una combinación de datos reales y señales sintéticas generadas mediante un esquema de sobresample diferenciado, en el cual las clases minoritarias recibieron una mayor cantidad de muestras sintéticas que las clases mayoritarias. El objetivo de este escenario fue evaluar el efecto de la aumentación de datos sobre la capacidad de generalización del modelo y el reconocimiento de las categorías menos representadas.

Modo D (REAL $\rightarrow$ test SINTÉTICO): el clasificador entrenado únicamente con datos reales fue evaluado sobre un conjunto de prueba completamente sintético generado con la misma distribución de clases del conjunto held-out. Este escenario sigue el paradigma Test on Real, Test on Synthetic (TRTS) y permite cuantificar la fidelidad de las señales sintéticas. Un desempeño similar al obtenido sobre el conjunto real indica que las señales generadas preservan adecuadamente las características estadísticas y morfológicas presentes en las señales electrocardiográficas originales.

Cabe señalar que la categoría *Others* fue excluida del entrenamiento y evaluación del clasificador debido a que agrupa múltiples diagnósticos cardíacos diferentes dentro de una misma etiqueta. Esta heterogeneidad dificulta que el modelo aprenda patrones electrocardiográficos representativos y consistentes para dicha clase. Además, su inclusión en la evaluación multiclase tiende a reducir las métricas globales, especialmente las métricas macro, ya que incorpora una categoría amplia y poco específica que presenta una mayor dificultad de clasificación.

D. Métricas de Evaluación del Generador

La calidad del generador se evaluó con métricas distribucionales: MMD² RBF (Maximum Mean Discrepancy), Sliced Wasserstein Distance (SWD), Distancia de Fréchet en el espacio latente (FLD), ratio de diversidad, coverage y memorization rate. Adicionalmente se realizó evaluación morfológica clínica mediante detección del pico R (Pan-Tompkins), medición de intervalos PR, QRS y QT (NeuroKit2), y DTW respecto a la señal media real por clase.

III. RESULTADOS

A. Entrenamiento del Generador

El modelo TCN-cVAE convergió en 140 épocas con una pérdida de reconstrucción en validación de 0.11811 y un gap train-val de -0.01837, lo que indica que no hay overfitting en el entrenamiento. El monitoreo de active units mostró 32/32 dimensiones latentes activas al finalizar el entrenamiento, indicando ausencia de posterior collapse.




Fig. 1. Curvas de aprendizaje del TCN-cVAE: pérdida total, MSE de reconstrucción, KL divergencia y active units por época.

B. Calidad de Señales Sintéticas

La Fig. 2 resume las métricas distribucionales promedio por clase. El ratio de diversidad ≈ 1.0 en todas las clases confirma ausencia de mode collapse. La memorization rate ≈ 0 indica que el modelo no memoriza ejemplos de entrenamiento. El coverage de 0.45-0.56 refleja una cobertura parcial del espacio real, atribuible al desbalance severo en clases como LVQRS (225 muestras) y PAC (362 muestras).




Fig. 2. Métricas de evaluación del generador TCN-cVAE por clase clínica.

La evaluación morfológica mostró una detección del pico R $\geq 80\%$ en [COMPLETAR: N/total] clases. Los intervalos PR medios en clases sin bloqueo (NSR, SB) fueron coherentes con el rango fisiológico (120–200 ms). Las clases LBBB y RBBB presentaron QRS > 120 ms, consistente con la morfología clínicamente esperada para bloqueos de rama.

C. Evaluación del Clasificador (TSTR)

La Tabla II compara las métricas del clasificador TCN en los tres modos de entrenamiento evaluados sobre el conjunto held-out (CLF_HELD).

TABLE II
Comparación de métricas del clasificador TCN — Test Held-Out

Modo	Accuracy	Recall	F1-macro	AUC-ROC*
A – REAL	35.47%	40.64%	32.73%	—
B – SINT-test REAL	41.03%	47.83%	40.38%	—

C – REAL+SINT	52.70%	55.65%	51.21%	–
D - REAL-test SINT	34.56%	50.30%	32.69%	-

* AUC-ROC: pendiente de cálculo en versión final.

El modo C (REAL+SINT) supera al modo A en recall macro (+15.02 pp) y al modo B en todas las métricas, evidenciando que las señales sintéticas aportan información complementaria para clases minoritarias. La caída de accuracy en modo C respecto a A se explica por la redistribución del peso de gradientes hacia clases subrepresentadas mediante Focal Loss.




Fig. 3. Métricas de clasificación por modo A, B, C y D




Fig. 4. Matrices de confusión del clasificador TCN en los modos A, B, C y D sobre el conjunto held-out.




Fig. 5. F1-score por clase en modo A (solo REAL) vs modo C (REAL+SINT).

Con el propósito de evaluar la fidelidad de las señales generadas por el TCN-cVAE, se empleó el paradigma Train on Real, Test on Synthetic (TRTS) en el modo D del clasificador. Para ello, se entrenó el clasificador TCN utilizando únicamente datos reales y posteriormente se evaluó su desempeño sobre un conjunto de señales completamente sintéticas.

Como se muestra en la Fig. 6, los resultados muestran que el clasificador mantiene un comportamiento similar al procesar ambos conjuntos de datos, lo que indica que las señales sintéticas preservan adecuadamente las características morfológicas y estadísticas presentes en los registros ECG originales. En otras palabras, el modelo no presenta una degradación significativa de su capacidad de clasificación al ser evaluado sobre señales generadas artificialmente, sugiriendo que estas poseen un nivel de realismo suficiente para ser interpretadas por el clasificador de manera comparable a las señales reales.




Fig. 6. Evaluación de Fidelidad (TRTS): Modelo entrenado en señales reales




Fig. 7. Comparación de matrices de Confusión

IV. DISCUSIÓN

Los resultados demuestran que el TCN-cVAE es capaz de sintetizar señales ECG morfológicamente plausibles con control clínico de clase. La mejora en recall macro del modo C confirma la hipótesis de que la aumentación con datos sintéticos beneficia principalmente a las clases con menor soporte real.

Sin embargo, se identifican limitaciones relevantes. Primero, el desbalance extremo del dataset limita la calidad del banco latente para clases minoritarias, afectando directamente el coverage distribucional. Segundo, la métrica F1-macro del modo C (30.31%) sigue siendo baja en términos absolutos, indicando que el problema de desbalance no se resuelve completamente con aumentación sintética. Tercero, la evaluación morfológica revela que algunas clases sintéticas presentan intervalos PR fuera del rango fisiológico, lo cual podría atribuirse a la variabilidad morfológica inherente de la clase o a limitaciones del modelo.

Desde el punto de vista clínico, las señales generadas no pueden emplearse directamente para diagnóstico. Su uso se limita a la fase de entrenamiento de modelos de clasificación como técnica de aumentación de datos. La validación morfológica (PR, QRS, QT, pico R) constituye una primera aproximación a la verificación clínica, pero requiere revisión por cardiólogos.

V. ANÁLISIS DE ERRORES

El análisis de las matrices de confusión revela que el clasificador presenta la mayor tasa de error en clases con escaso soporte real: LVQRS (225 muestras), PAC (362 muestras) y NSIVCB (1259 muestras). Estas clases muestran recall < 30% en el modo A, mejorando parcialmente en el modo C gracias al oversample sintético 10×.

La clase AFL (82% del dataset) domina el entrenamiento incluso con Focal Loss y WeightedSampler, generando un sesgo residual hacia la predicción de AFL en casos ambiguos. Este fenómeno es consistente con la literatura en clasificación de arritmias con datasets desbalanceados [7].

Desde el lado del generador, la clase NSR presenta los valores más altos de MMD² RBF y SWD, atribuible a la alta variabilidad morfológica intraclase de los ritmos sinusales normales y a la insuficiente capacidad del espacio latente (LATENT_DIM=32) para capturar esa variabilidad.

VI. CONCLUSIONES

Se presentó un sistema completo de generación y evaluación de señales ECG sintéticas basado en TCN-cVAE, entrenado sobre PhysioNet ECG-Arrhythmia. El modelo genera señales morfológicamente plausibles con control clínico de clase, verificado mediante métricas distribucionales y evaluación de intervalos clínicos. La evaluación TSTR demuestra que la aumentación con datos sintéticos mejora el recall macro sobre la línea base de solo datos reales, con beneficio concentrado en clases minoritarias.

Como trabajo futuro se propone: (1) explorar arquitecturas con mayor capacidad latente (LATENT_DIM=64-128) para clases de alta variabilidad como NSR; (2) implementar un discriminador adversarial auxiliar para reforzar la fidelidad

morfológica; (3) realizar validación clínica por cardiólogos expertos sobre muestras sintéticas seleccionadas; y (4) evaluar la generalización del pipeline sobre otros conjuntos de datos (MIMIC-IV-ECG, PTB-XL).

APÉNDICE: TABLA COMPARATIVA DE MODELOS

TABLE I

Comparación de arquitecturas generativas evaluadas

Modelo	Ventajas	Limitaciones	Seleccionado
LSTM-VAE	Simple, rápido	Sin cond. clínica	No
GAN 1D	Alta fidelidad	Inestable, mode collapse	No
CNN-cVAE	Mejor que LSTM	Campo receptivo corto	No
TCN-cVAE ✓	Campo rec. completo, WeightNorm	Mayor costo computacional	Si

REFERENCIAS

- [1]Hannun, A. et al., "Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network," Nature Medicine, vol. 25, pp. 65–69, 2019.
- [2]Goodfellow, I. et al., "Generative adversarial nets," Advances in Neural Information Processing Systems, vol. 27, 2014.
- [3]Kingma, D. P. y Welling, M., "Auto-Encoding Variational Bayes," arXiv:1312.6114, 2013.
- [4]Jordon, J. et al., "PATE-GAN: Generating synthetic data with differential privacy guarantees," ICLR, 2019.
- [5]Zheng, J. et al., "A 12-lead electrocardiogram database for arrhythmia research," PhysioNet, 2020. doi: 10.13026/wgex-er52.
- [6]Bai, S., Kolter, J. Z., y Koltun, V., "An empirical evaluation of generic convolutional and recurrent networks for sequence modeling," arXiv:1803.01271, 2018.
- [7]Johnson, J. M. y Khoshgoftaar, T. M., "Survey on deep learning with class imbalance," Journal of Big Data, vol. 6, no. 1, p. 27, 2019.